UTS MANAJEMEN INFORMASI

Nama : Tio Alan Kurniawan

NIM : 245314114

Instruksi: Lakukan pengolahan data pada dataset yang sudah diberikan menggunakan alat bantu Python /Spreadsheet. Jawablah pertanyaan-pertanyaan berikut secara komprehensif.

Bagian 1: Pengertian Data (Data Understanding)

1. **Identifikasi Variabel:** Sebutkan ke-7 nama kolom dalam dataset Anda dan jelaskan secara singkat representasi dunia nyata dari masing-masing kolom tersebut.

32_Streamer_Game.csv > data

```
Streamer_ID,Avg_Viewers,Peak_Viewers,Genre_Type,Donation_Amount,Hours_Streamed,Platform_Type
1001.0,626.38,39.26,6.23,48.23,219.55,Unknown
1002.0,827.44,21.69,0.01,36.58,697.08,Low
1003.0,627.32,89.24,3.25,83.39,165.62,Unknown
,616.2,73.08,4.68,15.83,87.19,High
1005.0,166.06,23.88,9.27,44.28,197.67,Unknown
1006.0,398.53,55.4,6.62,12.62,641.77,Low
,371.82,45.84,4.41,72.3,543.37,Unknown
1008.0,17.88,8.96,0.95,55.37,355.2,Low
1009.0,705.33,61.5,1.27,61.02,173.37,Medium
1010.0,902.69,53.71,8.79,55.04,698.45,High
1011.0,653.49,48.79,9.91,74.78,161.92,Low
1012.0,218.52,59.59,6.36,56.6,92.94,Medium
1013.0,190.1,19.91,4.24,22.69,552.57,Low
1014.0,923.82,99.25,0.05,70.09,634.61,Low
1015.0,663.49,16.08,2.91,0.56,731.35,Low
1016.0,802.57,35.06,6.1,64.14,230.96,Unknown
1017.0,797.7,29.09,9.56,19.67,,Medium
1018.0,658.02,,1.83,66.62,875.91,Unknown
1019.0,125.48,27.01,6.28,60.2,177.32,Low
1020.0,649.66,15.29,0.66,90.54,842.8,Medium
1021.0,410.77,0.52,0.84,17.01,253.1,Low
1022.0,428.56,34.99,3.22,47.65,630.6,Low
1023.0,117.95,24.97,9.1,0.99,597.3,Low
1024.0,52.0,38.02,9.27,38.54,252.39,High
1025.0,280.25,38.87,7.41,31.22,880.65,High
1026.0,797.49,60.06,4.44,28.92,208.91,High
1027.0,243.93,60.31,9.04,30.3,,High
,413.57,24.48,9.25,69.49,957.99,Low
```

	Streamer_ID	Avg_Viewers	Peak_Viewers	Genre_Type	Donation_Amount	\
0	1001.0	626.38	39.26	6.23	48.23	
1	1002.0	827.44	21.69	0.01	36.58	
2	1003.0	627.32	89.24	3.25	83.39	
3	NaN	616.20	73.08	4.68	15.83	
4	1005.0	166.06	23.88	9.27	44.28	
5	1006.0	398.53	55.40	6.62	12.62	
6	NaN	371.82	45.84	4.41	72.30	
7	1008.0	17.88	8.96	0.95	55.37	
8	1009.0	705.33	61.50	1.27	61.02	
9	1010.0	902.69	53.71	8.79	55.04	
10	1011.0	653.49	48.79	9.91	74.78	
11	1012.0	218.52	59.59	6.36	56.60	
12	1013.0	190.10	19.91	4.24	22.69	
13	1014.0	923.82	99.25	0.05	70.09	
14	1015.0	663.49	16.08	2.91	0.56	
15	1016.0	802.57	35.06	6.10	64.14	
16	1017.0	797.70	29.09	9.56	19.67	

Streamer_ID = ID unik untuk setiap streamer.
Avg_Viewers = Rata-rata jumlah penonton per streaming.
Peak_Viewers = Jumlah penonton maksimum yang pernah dicapai.
Genre_Type = Kategori genre game (kemungkinan dikodekan angka).
Donation_Amount = Jumlah donasi yang diterima streamer.
Hours_Streamed = Total jam streaming.
Platform_Type = Jenis platform (misalnya High, Low, Unknown).

2. **Klasifikasi Tipe Data:** Kelompokkan setiap kolom ke dalam tipe data yang tepat (Kualitatif/Kuantitatif) dan tentukan skala pengukurannya (Nominal, Ordinal, Interval, atau Ratio).

Kolom	Tipe Data	Skala
Streamer_ID	Kuantitatif	Nominal
Avg_Viewers	Kuantitatif	Rasio
Peak_Viewers	Kuantitatif	Rasio
Genre_Type	Kualitatif (encoded)	Nominal
Donation_Amount	Kuantitatif	Rasio
Hours_Streamed	Kuantitatif	Rasio
Platform_Type	Kualitatif	Nominal

3. **Struktur Data:** Berdasarkan jumlah baris dan kolom, jelaskan apakah data ini termasuk dalam kategori data terstruktur, semi-terstruktur, atau tidak terstruktur? Berikan alasannya.

Dataset ini termasuk dalam kategori data terstruktur karena memiliki jumlah baris dan kolom yang jelas, yaitu 3100 baris dan 7 kolom yang tersusun rapi dalam bentuk tabel. Setiap kolom memiliki nama dan representasi yang spesifik, seperti Avg_Viewers

dan Hours_Streamed, sehingga mudah dipahami dan dianalisis. Selain itu, masing-masing kolom memiliki tipe data yang konsisten, baik berupa numerik maupun kategori. Data juga disimpan dalam format CSV yang memang dirancang untuk data berbentuk tabel dan dapat dengan mudah diolah menggunakan perangkat lunak seperti Python atau Spreadsheet. Oleh karena itu, berdasarkan struktur yang terorganisir dan sistematis tersebut, dataset ini dapat dikategorikan sebagai data terstruktur.

Bagian 2: Deskripsi Data (Data Description)

1. **Statistik Deskriptif:** Hitunglah nilai Mean, Median, Standar Deviasi, Minimum, dan Maksimum untuk setiap kolom numerik. Apa yang bisa Anda simpulkan mengenai sebaran data tersebut?

```
=== STATISTIK DESKRIPTIF ===

            Streamer_ID  Avg_Viewers  Peak_Viewers  Genre_Type  Donation_Amount  \
mean         2552.40306   499.852893     49.294393    4.997958        49.430748
median       2555.00000   496.410000     48.270000    4.940000        49.810000
std           895.43892   283.440239     28.963459    2.903949        28.910800
min          1001.00000     0.090000      0.030000    0.000000         0.040000
max          4100.00000   999.920000     99.970000   10.000000        99.960000

            Hours_Streamed
mean            495.441367
median          494.470000
std             291.357019
min               0.020000
max             999.880000
```

Kesimpulan :

Dari data tersebut dapat disimpulkan bahwa nilai rata-rata (mean) dan median hampir sama, sehingga distribusi data cukup seimbang dan tidak terlalu miring. Namun, **standar deviasi yang besar** menunjukkan bahwa data memiliki variasi yang tinggi (nilainya tersebar jauh). Selain itu, selisih nilai minimum dan maksimum yang jauh menandakan adanya perbedaan besar antara data terendah dan tertinggi. Secara keseluruhan, data cukup merata tetapi memiliki penyebaran yang luas.

2. **Analisis Anomali:** Perhatikan nilai Minimum dan Maksimum. Apakah Anda menemukan nilai yang secara logika tidak mungkin (misal: suhu negatif ekstrem atau ID yang terduplikasi)? Sebutkan di kolom mana anomali tersebut ditemukan.

```
=== ANALISIS NILAI MIN & MAX ===

Streamer_ID
  Min : 1001.0
  Max : 4100.0

Avg_Viewers
  Min : 0.09
  Max : 999.92

Peak_Viewers
  Min : 0.03
  Max : 99.97

Genre_Type
  Min : 0.0
  Max : 10.0

Donation_Amount
  Min : 0.04
  Max : 99.96

Hours_Streamed
  Min : 0.02
  Max : 999.88
```

Berdasarkan hasil analisis nilai minimum dan maksimum, tidak ditemukan nilai yang tidak wajar seperti nilai negatif atau nilai ekstrem yang tidak masuk akal. Semua data masih berada dalam rentang yang logis. Selain itu, tidak ditemukan duplikasi pada kolom Streamer_ID, sehingga dapat disimpulkan bahwa dataset sudah bersih, konsisten, dan siap untuk dianalisis lebih lanjut.

3. **Visualisasi Distribusi:** Buatlah histogram untuk satu kolom numerik utama. Apakah distribusi datanya cenderung simetris (normal) atau memiliki kemiringan (*skewness*) tertentu?
   Histogram :

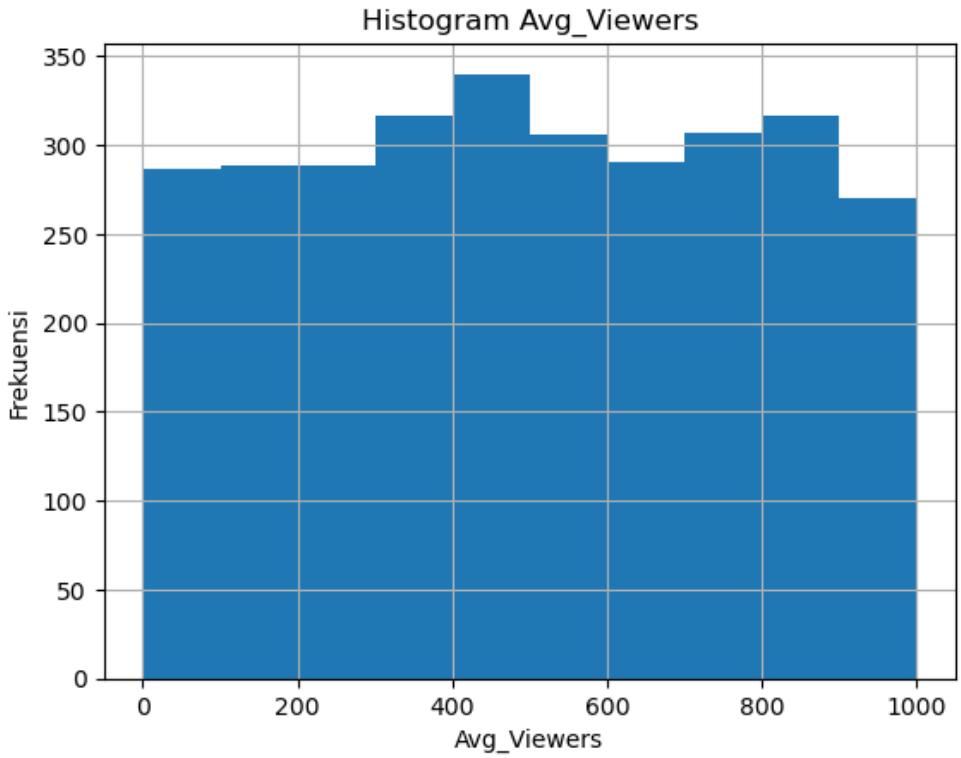


```
=== ANALISIS DISTRIBUSI ===

Nilai Skewness: -0.0075316191268565555
Distribusi miring ke kiri (negatively skewed)
```

Bagian 3: Pembersihan Data (Data Cleaning)

1. **Penanganan Missing Values:** Identifikasi kolom mana saja yang memiliki nilai kosong (NaN/NULL). Berapa persentasenya? Tentukan strategi apa yang Anda gunakan untuk mengatasinya (Imputasi atau Penghapusan) dan jelaskan alasannya.

```
=== CEK MISSING VALUES ===

                 Jumlah Missing  Persentase (%)
Streamer_ID                  93             3.0
Avg_Viewers                  93             3.0
Peak_Viewers                 93             3.0
Genre_Type                   93             3.0
Donation_Amount              93             3.0
Hours_Streamed               93             3.0
Platform_Type                93             3.0

=== ANALISIS MISSING VALUES ===

Streamer_ID memiliki 93 missing value (3.00%)
Avg_Viewers memiliki 93 missing value (3.00%)
Peak_Viewers memiliki 93 missing value (3.00%)
Genre_Type memiliki 93 missing value (3.00%)
Donation_Amount memiliki 93 missing value (3.00%)
Hours_Streamed memiliki 93 missing value (3.00%)
Platform_Type memiliki 93 missing value (3.00%)

=== PENANGANAN MISSING VALUES ===

Streamer_ID → diisi dengan MEAN (2552.40)
Avg_Viewers → diisi dengan MEAN (499.85)
...
```

Strategi yang saya gunakan untuk menangani missing values adalah imputasi**.** Alasannya**,** jumlah data yang hilang relatif kecil (sekitar 3% dari total data), sehingga jika dilakukan penghapusan (deletion), dikhawatirkan akan mengurangi jumlah data dan berpotensi menghilangkan informasi penting. Dengan menggunakan imputasi, data yang hilang dapat diisi tanpa mengurangi jumlah baris pada dataset.Untuk kolom numerik, nilai kosong diisi menggunakan mean (rata-rata) karena dapat merepresentasikan nilai tengah data secara umum. Sedangkan untuk kolom kategorikal, nilai kosong diisi menggunakan modus karena paling mewakili kategori yang dominan. Dengan strategi ini, dataset tetap lengkap dan tetap mempertahankan karakteristik aslinya sehingga lebih baik untuk analisis selanjutnya.

2. **Standardisasi Teks:** Jika terdapat kolom kategori/teks, periksa apakah ada ketidakkonsistenan penulisan (misal: perbedaan huruf kapital atau spasi berlebih). Tunjukkan langkah-langkah yang Anda lakukan untuk menyeragamkannya.

```
=== SEBELUM STANDARDISASI ===

['Unknown' 'Low' 'High' 'Medium']

=== SETELAH STANDARDISASI ===

['unknown' 'low' 'high' 'medium']
```

Proses standardisasi teks dilakukan untuk memastikan data pada kolom Platform_Type memiliki penulisan yang konsisten. Langkah pertama adalah menampilkan nilai unik pada kolom tersebut untuk melihat apakah terdapat perbedaan penulisan, seperti huruf besar dan kecil atau spasi yang tidak diperlukan. Setelah itu, dilakukan pembersihan dengan menggunakan fungsi strip() untuk menghapus spasi berlebih di awal maupun akhir teks. Langkah berikutnya adalah mengubah seluruh huruf menjadi huruf kecil menggunakan fungsi lower(), sehingga tidak ada lagi perbedaan antara penulisan seperti “High”, “HIGH”, atau “high”. Terakhir, nilai unik ditampilkan kembali untuk memastikan bahwa semua data sudah seragam. Dengan langkah-langkah ini, data menjadi lebih rapi, konsisten, dan siap digunakan untuk analisis lebih lanjut.

3. **Deteksi Outlier:** Gunakan metode *Interquartile Range* (IQR) atau *Boxplot* untuk menemukan pencilan. Apakah pencilan tersebut harus dihapus atau dipertahankan? Berikan argumen Anda.

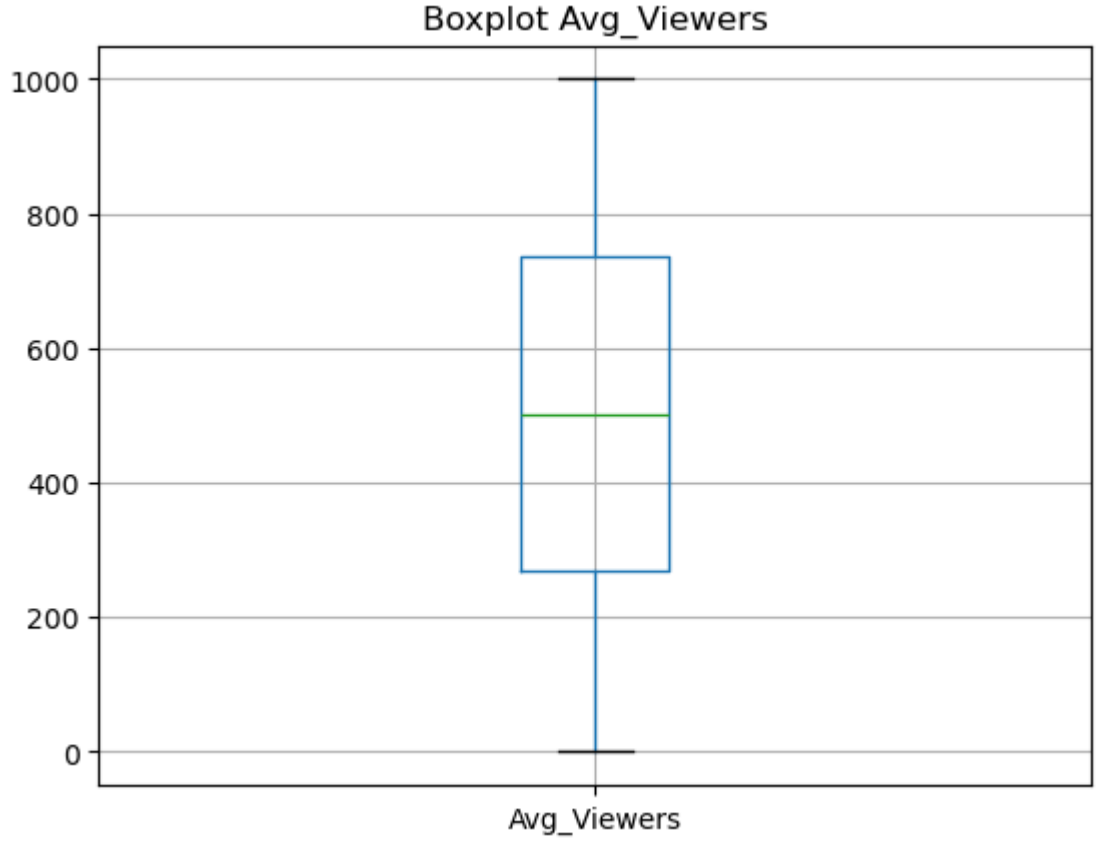

```
=== DETEKSI OUTLIER (IQR) ===

Streamer_ID
Jumlah outlier: 0
Batas bawah : -461.0
Batas atas  : 5565.0

Avg_Viewers
Jumlah outlier: 0
Batas bawah : -431.92500000000007
Batas atas  : 1435.875

Peak_Viewers
Jumlah outlier: 0
Batas bawah : -49.223749999999974
Batas atas  : 147.30624999999998

Genre_Type
Jumlah outlier: 0
Batas bawah : -4.55625
Batas atas  : 14.57375

Donation_Amount
Jumlah outlier: 0
Batas bawah : -49.168749999999996
```

```
Genre_Type
Jumlah outlier: 0
Batas bawah : -4.55625
Batas atas  : 14.57375

Donation_Amount
Jumlah outlier: 0
Batas bawah : -49.168749999999996
...
Jumlah outlier: 0
Batas bawah : -492.3824999999998
Batas atas  : 1481.9574999999998

Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

Berdasarkan hasil perhitungan metode IQR dan visualisasi boxplot, tidak ditemukan outlier pada data, karena semua nilai masih berada di dalam batas bawah dan batas atas yang telah ditentukan. Oleh karena itu, tidak ada data yang perlu dihapus. Semua data sebaiknya dipertahankan, karena masih berada dalam rentang yang wajar dan tidak menunjukkan adanya penyimpangan ekstrem. Selain itu, dalam konteks data streamer, variasi nilai seperti jumlah penonton yang tinggi atau rendah merupakan hal yang normal dan mencerminkan kondisi nyata. Kesimpulannya, karena tidak terdapat pencilan (outlier), maka seluruh data dapat digunakan tanpa perlu dilakukan penghapusan, sehingga informasi dalam dataset tetap lengkap dan tidak berkurang.

Bagian 4: Transformasi Data (Data Transformation)

1. **Feature Scaling:** Lakukan normalisasi (Min-Max Scaling) atau standardisasi (Z-Score) pada kolom numerik. Tunjukkan perbandingan nilai sebelum dan sesudah transformasi. Mengapa tahap ini penting untuk analisis data?

```
=== SEBELUM SCALING ===

   Avg_Viewers  Peak_Viewers  Donation_Amount  Hours_Streamed
0       626.38         39.26            48.23          219.55
1       827.44         21.69            36.58          697.08
2       627.32         89.24            83.39          165.62
3       616.20         73.08            15.83           87.19
4       166.06         23.88            44.28          197.67

=== SESUDAH SCALING ===

   Avg_Viewers  Peak_Viewers  Donation_Amount  Hours_Streamed
0     0.626396      0.392536         0.482286        0.219561
1     0.827491      0.216730         0.365693        0.697158
2     0.627337      0.892636         0.834167        0.165623
3     0.616215      0.730939         0.158026        0.087182
4     0.165998      0.238643         0.442754        0.197678
```

Normalisasi penting karena membuat semua data memiliki skala yang sama (0–1), sehingga tidak ada variabel yang lebih dominan. Dengan begitu, data bisa dibandingkan secara adil dan hasil analisis menjadi lebih akurat serta stabil.

2. **Encoding Data Kategorikal:** Ubah kolom kategori yang bersifat Nominal menjadi format angka menggunakan *One-Hot Encoding*, atau kolom bersifat Ordinal menggunakan *Label/Ordinal Encoding*. Jelaskan mengapa Anda memilih metode tersebut.

```
=== SEBELUM ENCODING ===

  Platform_Type
0       unknown
1           low
2       unknown
3          high
4       unknown

=== SESUDAH ENCODING ===

   Streamer_ID  Avg_Viewers  Peak_Viewers  Genre_Type  Donation_Amount  \
0   1001.00000       626.38         39.26        6.23            48.23
1   1002.00000       827.44         21.69        0.01            36.58
2   1003.00000       627.32         89.24        3.25            83.39
3   2552.40306       616.20         73.08        4.68            15.83
4   1005.00000       166.06         23.88        9.27            44.28

   Hours_Streamed  Platform_Type_high  Platform_Type_low  \
0          219.55               False              False
1          697.08               False               True
2          165.62               False              False
3           87.19                True              False
4          197.67               False              False
```

```
...
1                False                False
2                False                 True
3                False                False
4                False                 True
Output is truncated. View as a scrollable element or open in a text editor. A
```

Metode yang digunakan adalah One-Hot Encoding karena kolom Platform_Type bersifat nominal, yaitu tidak memiliki urutan atau tingkatan tertentu. Jika menggunakan Label Encoding, maka akan muncul angka yang seolah-olah memiliki urutan (misalnya 0, 1, 2), padahal sebenarnya tidak. Oleh karena itu, One-Hot Encoding dipilih karena dapat merepresentasikan setiap kategori secara terpisah tanpa menimbulkan bias urutan, sehingga lebih tepat untuk analisis data.

3. **Feature Engineering:** Buatlah satu kolom baru (fitur turunan) hasil dari manipulasi atau kombinasi kolom yang sudah ada. Jelaskan bagaimana kolom baru ini dapat memberikan wawasan tambahan bagi analisis Anda.

```
=== SEBELUM FEATURE ENGINEERING ===

   Avg_Viewers  Peak_Viewers
0       626.38         39.26
1       827.44         21.69
2       627.32         89.24
3       616.20         73.08
4       166.06         23.88

=== SESUDAH FEATURE ENGINEERING ===

   Avg_Viewers  Peak_Viewers  Engagement_Ratio
0       626.38         39.26         15.954661
1       827.44         21.69         38.148456
2       627.32         89.24          7.029583
3       616.20         73.08          8.431856
4       166.06         23.88          6.953936
```

Fitur baru yang dibuat adalah Engagement_Ratio, yaitu hasil perbandingan antara rata-rata penonton *(*Avg_Viewers*)* dengan jumlah penonton maksimum *(*Peak_Viewers*)*. Kolom ini memberikan wawasan tambahan mengenai tingkat konsistensi penonton pada setiap streamer. Nilai yang mendekati 1 menunjukkan bahwa jumlah penonton relatif stabil, sedangkan nilai yang lebih kecil menunjukkan adanya perbedaan yang besar antara penonton rata-rata dan puncak. Dengan adanya fitur ini, analisis tidak hanya melihat jumlah penonton, tetapi juga kualitas dan kestabilan performa streamer.

Kesimpulan dataset sebelum dan sesudah dilakukan pembersihan :

Secara keseluruhan, kualitas dataset sebelum dilakukan pembersihan sudah cukup baik karena tidak ditemukan anomali ekstrem atau duplikasi data. Namun, masih terdapat beberapa kekurangan seperti adanya missing values dan potensi ketidakkonsistenan penulisan pada data kategorikal.

Setelah dilakukan proses pembersihan dan transformasi, dataset menjadi lebih lengkap, konsisten, dan siap untuk dianalisis lebih lanjut. Proses imputasi berhasil mengatasi nilai yang hilang tanpa mengurangi jumlah data, sedangkan normalisasi dan encoding membuat data lebih terstruktur dan mudah digunakan dalam berbagai metode analisis. Dengan demikian, kualitas dataset setelah pembersihan menjadi lebih baik dan lebih representatif untuk menghasilkan analisis yang akur